

2팀

HEALTHHAT / AI MEDICINE SERVICE

사전 한 장에서 시작하는 안전한 약품 확인

Health Hat · AI 약품 개별인식, 의료지식기반 검색

AI 기반 이미지 인식

데이터 분류/모델 분석

안전한 복용 가이드



타이레놀 500mg 1정

로수바스타틴 10mg 1정
고지혈증 치료제



안전한 복용을 위한
AI 분석 시스템 >

2팀

HEALTHHAT / AI MEDICINE SERVICE

사전 한 장에서 시작하는 안전한 약품 확인



AI × HEALTHCARE



김혜린

PM



역할

기획 · 커뮤니케이션 · PM



담당

프로젝트 기획 및 일정 관리



강인호

Data Engineer



역할

데이터 수집 · 전처리



담당

EDA · 라벨링 · 전처리



유영관

Model Architect



역할

모델 · 학습 파이프라인



담당

모델 학습 · 성능 개선

01

문제 정의와 목표

단순한 약품 인식을 넘어,
사용자의 '안전한 복용'을 위한 AI 서비스

Safer
Health
with AI



기존 문제점



다양한 약품의 유사한 형태
(운동 가능성)



촬영 환경에 따른 인식률 저하
(각도, 조명, 거리 등)



소수 클래스의 데이터 부족
(불균형한 데이터 분포)



잘못된 복용으로 인한
건강 위협 가능성



Health Eat의 목표



정확한 약품 식별
(이름 + 위치)



다양한 촬영 조건에서의
강건한 인식




안전한 복용을 위한
검증 시스템 구축



실제 서비스로 연결되는
사용자 중심 AI






01

홈


서비스 소개와 주요 기능을 한눈에 확인할 수 있습니다.



02

약품 촬영


AI가 정확한 분석을 위해 선명한 이미지를 촬영합니다.



03

AI 분석 중


이미지 품질부터 약품 식별까지 AI가 순차적으로 분석합니다.



04

약품 기록

복용 중인 약품을 체계적으로 관리하고, 복용 알림을 설정할 수 있습니다.



05

복약 알림

복용 시간을 설정하고 알림을 통해 꾸준한 복용을 도와줍니다.



06

건강 정보

약품 정보, 건강 상식, 복약 팁 등 다양한 콘텐츠를 제공합니다.



경구약제 이미지 보조 식별 서비스

Health Eat은 사용자가 촬영한 약 사진을 분석하여
약품의 위치와 종류를 식별하고, 복용 전 정확한 정보를 확인할 수 있도록 돕는
AI 기반 헬스케어 서비스입니다.



정확한 식별
(위치 + 클래스)



안전한 복용
(추가 확인 안내)



건강한 일상
(지속적인 관리)



가장 신뢰할 수 있는 모델을 선택했습니다.

01 Input Image




사용자가 촬영한
약 이미지

02 Preprocessing



- Resize
- Normalize
- Augmentation

03 Detector



RetinaNet / YOLO
(다중 객체 탐지)

04 Post Processing




- NMS
- Confidence Filtering
- Top-K 제거

05 Candidate Matching



약품 데이터베이스와
매칭하여 후보 도출

06 Result



위치, 약품명, 신뢰도 제공
(추가 확인 필요 시 안내)



더 정확하고 안전한
복약 관리를 위해,
Health Eat이 함께합니다.



AI 기반
고정확도 약품 식별



실시간
안전성 검증



개인 맞춤형
건강 정보 제공



건강한 일상을 위한
스마트한 선택

Model Architecture

YOLO26 기반의 End-to-End 단일 단계 탐지 구조

본 프로젝트에서는 YOLO26을 활용해, 다양한 크기와 형태의 약품을 정확하게 탐지할 수 있는 딥러닝 기반 객체 탐지 모델을 구축하였습니다.

1 Input Image

(640x640)



2 Backbone

Feature Extraction




3 Neck

Multi-scale Fusion (P3-P5)



4 Detection Head

Classification + Box Regression



NMS-Free End-to-End 추론

후처리(NMS) 없이 모델이 최종 탐지 결과를 바로 출력합니다. DFL을 제거해 헤드가 가벼워져 배포와 연동도 쉬워집니다.

기존 방식

Model



NMS



Result

YOLO26

Model



Final Detections

STAL · ProgLoss · MuSGD

작은 객체에 유리한 라벨 할당(STAL)과 손실 가중치를 점진적으로 조절하는 ProgLoss, 학습을 안정시키는 MuSGD 옵티마이저로 작은 알약 탐지와 학습 안정성을 높입니다.

STAL

작은 객체 라벨 할당

ProgLoss

손실 균형 점진 조절

MuSGD

학습 안정화

데이터 파이프라인

다양한 출처의 데이터를 수집하고, 체계적인 전처리와 검증을 통해 모델 학습에 최적화된 데이터셋을 구축했습니다.

01



데이터 수집

- 공식 데이터
- AI-Hub 추가 수집
(외부 데이터 활용)

02



전처리

- 이미지 리사이징
- 노이즈 제거
- 정규화

03



어노테이션

- bbox 라벨링
- 클래스 매핑
- 품질 검증

04



학습셋 구성

- Train / Val / Test
- 클래스 균형 조정
- 데이터 증강



최종 데이터셋

232장

(공식 데이터)

+

10,500장

(추가 수집 데이터)

=

총 10,732장

클래스 분포




다수 클래스
(78%)


소수 클래스
(22%)

Bounding Box 수동 검수

pill_bbox_reviewer.py로 이미지와 어노테이션을 하나씩 확인하며 학습에 부적합한 이미지를 골라냈습니다.



검수 화면 (1)



검수 화면 (2)

초록 체크로 선택한 이미지는 제외 대상으로 분리(deleted_imgs)됩니다.

모델 실험 결과

다양한 모델을 비교하고, 데이터 특성에 맞는 **최적의 모델**을 선택했습니다.

최종적으로 성능을 도출했습니다.

 모델	 백본(Backbone)	 주요 결과 (mAP@0.75:0.95)	 비교
01 SSD300	VGG16	0.5637 (local)	Baseline
02 RetinaNet	ResNet50-FPN	0.35127 (public)	분류형/멀티스케일
03 Faster R-CNN	ResNet50-FPN v2	0.7986 (local)	2-stage 비교
04 RTMDet-l	RTMDet	0.506 (local)	다른 one-stage
05 YOLO26s	YOLO26	 0.986~0.988 (local)	Validation 한계로 일반화 성능으로 해석 X



다양한 모델 실험

여러 모델을 비교하여
데이터 특성에 맞는 최적의 모델을 선정했습니다.



데이터 기반 평가

공개/로컬 점수를 모두 고려하여
신뢰할 수 있는 성능을 분석했습니다.



성능 검증

단순한 수치가 아닌,
실제 서비스 환경을 고려한 성능을 평가했습니다.



최적 모델 선정

최종적으로 YOLO26s를
프로젝트의 핵심 모델로 선택했습니다.

더 정확한 예측,
더 안전한 복용

왜 YOLO26을 최종 모델로 선택했는가?

프로젝트에서 실제로 관찰한 탐지 문제를 모델 설계 요소에 연결해 최종 모델을 정했습니다.

INPUT

 640×640

BACKBONE

Feature Extractor

NECK

P3-P5 Multi-scale

HEAD

Dual Head · NMS-Free

01 Small / Multi-scale Objects

DESIGN → STAL + Multi-scale

작은 알약에 학습 신호를 더 주는 라벨 할당(STAL)과
다중 스케일 특징 활용

02 Post-processing Simplicity

DESIGN → NMS-Free End-to-End

NMS 없이 최종 결과를 바로 출력해 후처리 단계를
단순화

03 Training Stability / Deployment

DESIGN → ProgLoss · MuSGD · DFL-free

안정적인 학습과 가벼운 헤드로 서비스 배포·연동에
유리

WHY YOLO26

YOLO26은 mAP 수치만이 아니라, 작은 알약 탐지·후처리 단순화·서비스 연동까지 함께 고려해 선택했습니다.

SSD300 · RetinaNet · Faster R-CNN · RTMDet과 비교한 실험 결과를 바탕으로 최종 모델로 선정



232장으로 시작해, 8,068장의 학습 기반으로 확장했다

데이터 확장은 '양을 늘리는 작업'이 아니라 클래스 커버리지와 일반화 가능성을 넓히는 실험이었다.



DATA EXPANSION — WHAT CHANGED?

이미지 수 **232** → **8,068** 학습 이미지 클래스 **56** → **118** 확장 범위

핵심 '더 많은 이미지'와 '더 넓은 클래스 커버리지'를 분리해서 바라볼 필요가 있었다.





데이터를 늘린 것과 클래스를 확장한 것을 분리해서 보았다

Faster R-CNN 기준 실험으로 데이터 규모와 클래스 구성 변화의 영향을 확인했다.

0.30

Case 1

232 images · 56 classes

0.34423

Case 3

2,846 images · 56 classes

0.48821

Case 2

3,730 images · 118 classes

+0.144

Case 3 → 2

class scope expansion

KAGGLE SCORE



INTERPRETATION

이미지 수만 늘리는 것보다
클래스 다양성이 포함된 확장이
더 큰 차이를 만들 가능성을 확인

※ 완전한 인과 분리는 아니므로 추가 통제가 필요





알약 bbox는 생각보다 느슨하고 일정하지 않았다

pill_bbox_reviewer.py로 이미지와 어노테이션을 하나씩 대조해 확인한 결과다.

WHAT WE FOUND

AI Hub 어노테이션의 bbox는 균일하지 않다

LOOSE BOX

빨간 알약 등 일부 알약의 박스가 알약보다 느슨하게 잡혀 있음

INCONSISTENT

비슷한 위치의 알약끼리도 박스의 여유 정도가 제각각

OFF-TARGET

박스가 알약에서 크게 벗어나거나, 박스가 없는 알약이 포함된 이미지 존재

ACTION

육안 검수로 약 600장(전체의 약 6%)을 학습에서 제외



알약 bbox 예시 (화질 개선·확대)

박스 품질이 학습 결과에 직접 영향을 준다

모델을 바꾸기 전에, 학습 데이터의 bbox 품질부터 확인했다.



느슨한 Bounding Box를 GrabCut으로 타이트하게 보정해 보았다

빨간색은 원본 bbox, 초록색은 GrabCut 제안 박스이며, 사람이 승인·거절하며 보정할 박스를 골랐다.



GrabCut 제안 박스 검수 화면 (1)



GrabCut 제안 박스 검수 화면 (2)

핵심 박스를 알약에 딱 맞게 보정해 학습하자 Kaggle 점수는 오히려 낮아졌다.

→ Kaggle 정답 csv가 느슨한 박스 기준으로 만들어졌을 것이라는 가설



성능 숫자를 넘어, '어떻게 틀리는가'를 정의한다

실제 서비스에서는 평균 mAP보다 오류 유형별 대응 전략이 중요하다.

FALSE POSITIVE

없는 약을 있다고 탐지

FALSE NEGATIVE

있는 약을 놓침

CLASS CONFUSION

유사 약품을 다른 class로

BAD LOCALIZATION

bbox 위치·크기 부정확

UNKNOWN

학습 밖 대상을 기존 class로

IMAGE FAILURE

흐림·어두움·잘못된 사진

이 taxonomy가 있어야 '어떤 데이터를 추가할지 / 어떤 후처리를 바꿀지 / 어떤 모델을 재학습할지'가 결정된다.





모델의 confidence를 그대로 '정답'으로 보여주지 않는다

실사용 환경에서는 이미지 품질과 불확실성을 함께 판단하는 safety gate가 필요하다.



SAFETY GATE

확실하지 않으면
'확인 필요'로 전환

서비스 원칙

AI는 식별을 돕고 · 사용자는 최종 확인 · 불확실한 결과는 숨기지 않는다



Production AI Pipeline · Safety

모델의 raw prediction을 바로 사용자 결과로 보여주지 않고, 품질과 불확실성을 거친 뒤 결과로 연결하는 구조입니다.



모델 출력 상태를 분리




AI가 항상 답을 내야 하는 것은 아닙니다.

확실하게 도울 수 있을 때는 결과를 보여주고, 확신할 수 없을 때는 '확인이 필요함'을 보여주는 구조가 필요합니다.

실제 서비스 데모 영상

촬영부터 AI 분석, confidence 표시까지 실제 기기에서 동작하는 화면입니다.



▶ 실제 촬영 → AI 분석 → 신뢰도 표시 (예시: 게보린정 300mg, 인식 신뢰도 49.4%)

Health Eat · 총 재생시간 1분 26초 · 편집 없이 실제 기기 화면 그대로입니다



다음 단계는 '더 큰 모델'이 아니라 '더 강한 일반화'다

현재 프로젝트에서 발견한 문제를 연구 과제로 연결해, 실제 촬영 환경에서 재현 가능한 시스템으로 발전시킨다.

01

VALIDATION

Group-aware split
Near-duplicate 제거
Independent test

02

ROBUSTNESS

Blur / low-light
Occlusion / background
OOD / unknown

03

LEARNING LOOP

Hard negative
Active learning
Model monitoring

PROJECT PRINCIPLE

높은 mAP를 만드는 것에서 끝나지 않고, '언제 믿을 수 있는가'를 검증하는 AI를 만든다.



모델 성능을 넘어, 전체 파이프라인의 신뢰도를 높입니다.

이번 프로젝트에서 확인한 문제를 데이터 품질과 검증 신뢰성의 개선 과제로 연결했습니다.

DATA QUALITY

01

데이터가 흔들리면 모델의 성능도 흔들립니다.

학습 이전에 데이터의 구조·좌표·라벨·중복을 자동 검증하는 체계가 필요합니다.

발견한 문제

- area:null / BBox 오류
- 중복 Annotation
- 클래스 충돌
- dl_idx / 매핑코드 불일치
- AI-Hub 유사 이미지

개선 방향

- Annotation Schema · BBox 자동 검증
- 중복·유사 이미지 탐지
- Class Mapping Version 관리
- Canonical Label 고정
- Dataset Integrity Check

VALIDATION RELIABILITY


02

높은 점수보다 믿을 수 있는 점수.

Local mAP가 실제 일반화 성능을 대표하는지 검증하기 위해 split 전략 자체를 개선합니다.

기존

개선



핵심 | 깨끗한 데이터 → 믿을 수 있는 검증 → 실제 서비스에서 재현되는 성능

다음 단계는 ‘더 높은 점수’가 아니라 ‘더 견고한 AI’입니다.

실제 촬영 환경과 불확실성까지 고려해, 탐지에서 안전한 확인까지 확장합니다.

01

ROBUSTNESS

촬영 환경 일반화

실제 사용자 촬영 이미지에서 성능 변동을 줄입니다.

각도

조명

배경

초점

모션 블러

저조도

→ Real-world Augmentation

Domain Shift 대응을 위한
실환경 중심 데이터 확장

02

OOD / UNKNOWN

모르는 상황을 구분

모델이 확신할 수 없는 경우를
‘확인 필요’로 전환합니다.

KNOWN

정상 결과

LOW QUALITY

재촬영

UNKNOWN

확인 필요

NO DETECTION

식별 불가

Confidence / OOD Gate

03

IDENTIFICATION

탐지에서 확인까지

Detection 결과를 후보 매칭과
사용자 확인으로 연결합니다.

IMAGE

QUALITY CHECK

DETECTION

CANDIDATE MATCHING

MEDICINE DB

USER CONFIRMATION

완료

탐지 → 확인까지 하나의 AI 흐름

마무리

우리가 만든 것은 단순한 모델이 아니었습니다.

“AI가 모든 약을 맞히는 서비스를 만들고자 한 것이 아닙니다.”

AI가 확실하게 도울 수 있는 순간과,
사람이 반드시 확인해야 하는 순간을 구분하는 서비스를 만들고자 했습니다.

01

MODEL

높은 mAP보다
검증 가능한 성능

02

DATA

많은 데이터보다
믿을 수 있는 데이터

03

SERVICE

정확한 답보다
안전한 답변 구조

HEALTH EAT · BETTER HEALTH, TOGETHER

감사합니다.