

2팀

HEALTHHAT / AI MEDICINE SERVICE

사전 한 장에서 시작하는 안전한 약품 확인



Health Hat · AI 약품 개별인식, 의료지식기반 검색



AI 기반 이미지 인식



데이터 분류/모델 분석



안전한 복용 가이드



타이레놀 500mg

1정



로수바스타틴 10mg
고지혈증 치료제

1정



안전한 복용을 위한
AI 분석 시스템



사전 한 장에서 시작하는 안전한 약품 확인



AI × HEALTHCARE

**김혜린**

PM



역할

기획 · 커뮤니케이션 · PM



담당

프로젝트 기획 및 일정 관리

**강인호**

Data Engineer



역할

데이터 수집 · 전처리



담당

EDA · 라벨링 · 전처리

**유영관**

Model Architect



역할

모델 · 학습 파이프라인



담당

모델 학습 · 성능 개선

01

문제 정의와 목표

단순한 약품 인식을 넘어,
사용자의 '안전한 복용'을 위한 AI 서비스

Safer
Health
with AI



기존 문제점



다양한 약품의 유사한 형태
(운동 가능성)



촬영 환경에 따른 인식률 저하
(각도, 조명, 거리 등)



소수 클래스의 데이터 부족
(불균형한 데이터 분포)



잘못된 복용으로 인한
건강 위협 가능성



Health Eat의 목표



정확한 약품 식별
(이름 + 위치)



다양한 촬영 조건에서의
강건한 인식




안전한 복용을 위한
검증 시스템 구축



실제 서비스로 연결되는
사용자 중심 AI






01

홈


서비스 소개와 주요 기능을 한눈에 확인할 수 있습니다.



02

약품 촬영


AI가 정확한 분석을 위해 선명한 이미지를 촬영합니다.



03

AI 분석 중


이미지 품질부터 약품 식별까지 AI가 순차적으로 분석합니다.



04

약품 기록

복용 중인 약품을 체계적으로 관리하고, 복용 알림을 설정할 수 있습니다.



05

복약 알림

복용 시간을 설정하고 알림을 통해 꾸준한 복용을 도와줍니다.



06

건강 정보

약품 정보, 건강 상식, 복약 팁 등 다양한 콘텐츠를 제공합니다.



경구약제 이미지 보조 식별 서비스

Health Eat은 사용자가 촬영한 약 사진을 분석하여
약품의 위치와 종류를 식별하고, 복용 전 정확한 정보를 확인할 수 있도록 돕는
AI 기반 헬스케어 서비스입니다.



정확한 식별
(위치 + 클래스)



안전한 복용
(추가 확인 안내)



건강한 일상
(지속적인 관리)



가장 신뢰할 수 있는 모델을 선택했습니다.

01 Input Image




사용자가 촬영한
약 이미지

02 Preprocessing



- Resize
- Normalize
- Augmentation

03 Detector



RetinaNet / YOLO
(다중 객체 탐지)

04 Post Processing




- NMS
- Confidence Filtering
- Top-K 제거

05 Candidate Matching



약품 데이터베이스와
매칭하여 후보 도출

06 Result



위치, 약품명, 신뢰도 제공
(추가 확인 필요 시 안내)



더 정확하고 안전한
복약 관리를 위해,
Health Eat이 함께합니다.



AI 기반
고정확도 약품 식별



실시간
안전성 검증



개인 맞춤형
건강 정보 제공



건강한 일상을 위한
스마트한 선택

Model Architecture


RetinaNet + ResNet50-FPN을 기반으로 한 딥얼 단계 탐지 구조

본 프로젝트에서는 RetinaNet과 ResNet50-FPN을 결합하여, 다양한 크기와 형태의 약품을 정확하게 탐지할 수 있는 딥러닝 기반 객체 탐지 모델을 구축하였습니다.

1 Input Image (640x640)



2 Backbone ResNet50



3 FPN (Feature Pyramid Network)




4 Detection Head (Classification + Regression)




Focal Loss

다수의 배경 클래스와 소수의 약품 클래스 불균형 문제를 완화하여, 작은 객체 탐지 성능을 향상시킵니다.

일반적인 Loss



Focal Loss (ours)



Multi-scale Feature (FPN)

다양한 스케일의 feature를 활용하여 작은 약품부터 큰 약품까지 정확하게 탐지합니다.



데이터 파이프라인

다양한 출처의 데이터를 수집하고, 체계적인 전처리와 검증을 통해 모델 학습에 최적화된 데이터셋을 구축했습니다.

01



데이터 수집

- 공식 데이터
- AI-Hub 추가 수집
(외부 데이터 활용)

02



전처리

- 이미지 리사이징
- 노이즈 제거
- 정규화

03



어노테이션

- bbox 라벨링
- 클래스 매핑
- 품질 검증

04



학습셋 구성

- Train / Val / Test
- 클래스 균형 조정
- 데이터 증강



최종 데이터셋

232장

(공식 데이터)

+

8,068장

(추가 수집 데이터)

=

총 8,300장

클래스 분포



다수 클래스
(78%)

소수 클래스
(22%)

모델 실험 결과

다양한 모델을 비교하고, 데이터 특성에 맞는 **최적의 모델**을 선택했습니다.

최종적으로 성능을 도출했습니다.

 모델	 백본(Backbone)	 주요 결과 (mAP@0.75:0.95)	 비교
01 SSD300	VGG16	0.5637 (local)	Baseline
02 RetinaNet	ResNet50-FPN	0.35127 (public)	분류형/멀티스케일
03 Faster R-CNN	ResNet50-FPN v2	0.7986 (local)	2-stage 비교
04 RTMDet-l	RTMDet	0.506 (local)	다른 one-stage
05 YOLOv8s	YOLOv8	 0.986~0.988 (local)	Validation 한계로 일반화 성능으로 해석 X



다양한 모델 실험

여러 모델을 비교하여
데이터 특성에 맞는 최적의 모델을 선정했습니다.



데이터 기반 평가

공개/로컬 점수를 모두 고려하여
신뢰할 수 있는 성능을 분석했습니다.



성능 검증

단순한 수치가 아닌,
실제 서비스 환경을 고려한 성능을 평가했습니다.



최적 모델 선정

최종적으로 YOLOv8s를
프로젝트의 핵심 모델로 선택했습니다.

더 정확한 예측,
더 안전한 복용



알약 사진 한 장에서, '무엇'과 '어디'를 동시에 찾아야 한다

Health Eat의 핵심은 단순 분류가 아니라 다중 객체의 위치·종류를 함께 추정하는 것이다.

56

대상 클래스

competition 기준

232

원본 이미지

초기 학습 데이터

mAP

@[0.75:0.95]

높은 IoU 구간 평가

≤ 4

약제 / image

다중 객체 검출

WHY DETECTION?

분류만으로는 부족하다

MULTI-OBJECT

한 장에 여러 알약이 동시에 존재

LOCALIZATION

약품별 위치와 크기까지 정확히 찾아야 함

CORE CHALLENGE

촬영 환경의 불확실성

DATA SCARCITY

소수 클래스의 학습 샘플 부족

DOMAIN SHIFT

카메라 각도·조명·배경 변화



왜 Object Detection인가?

Health Eat의 출력은 '약 이름'에서 끝나지 않고, 이미지 안의 '위치'까지 포함해야 합니다.

PROBLEM FRAMING

한 장의 사진 안에
여러 약제가 있을 수 있습니
다.

필요한 출력

**WHAT + WHERE + HOW
SURE**

무엇인가 → class

어디에 있는가 → bbox

얼마나 확신하는가 → confidence

사용자 화면에서는 기술 용어를 숨기되,
내부 inference에서는 세 요소를 분리해
명확하게 다룹니다.

Classification vs Object Detection

CLASSIFICATION

Image → Class



“〇〇정”

위치 정보 없음

→ 이미지 전체를 하나의 class로 판단

DETECTION

Image → [Class + BBox] × N



MULTIPLE OBJECTS

한 이미지에 여러 약제

LOCALIZATION

약제의 위치가 필요

METRIC

mAP@[0.75:0.95]

왜 RetinaNet을 기준 모델로 선택했는가?

프로젝트에서 실제로 관찰한 탐지 문제를 모델 설계 요소에 연결해 기준 모델을 정했습니다.



01

Small / Multi-scale Objects

DESIGN → FPN

서로 다른 크기의 약제를 여러 feature scale에서 표현

02

Class Imbalance

DESIGN → WeightedRandomSampler

희소 클래스가 학습에서 묻히지 않도록 샘플링 보완

03

Foreground / Background Imbalance

DESIGN → Focal Loss

쉬운 배경보다 어려운 객체에 학습을 집중

WHY BASELINE

RetinaNet을 최종 정답이 아니라, 불균형·멀티스케일·Localization을 검증하기 위한 기준으로 활용했습니다.

이후 Faster R-CNN · RTMDet · YOLO 계열과 비교하며 모델 선택 기준을 확장



232장으로 시작해, 8,068장의 학습 기반으로 확장했다

데이터 확장은 '양을 늘리는 작업'이 아니라 클래스 커버리지와 일반화 가능성을 넓히는 실험이었다.



DATA EXPANSION — WHAT CHANGED?

이미지 수 **232** → **8,068** 학습 이미지 클래스 **56** → **118** 확장 범위

핵심 '더 많은 이미지'와 '더 넓은 클래스 커버리지'를 분리해서 바라볼 필요가 있었다.





데이터를 늘린 것과 클래스를 확장한 것을 분리해서 보았다

Faster R-CNN 기준 실험으로 데이터 규모와 클래스 구성 변화의 영향을 확인했다.

0.30

Case 1

232 images · 56 classes

0.34423

Case 3

2,846 images · 56 classes

0.48821

Case 2

3,730 images · 118 classes

+0.144

Case 3 → 2

class scope expansion

KAGGLE SCORE



INTERPRETATION

이미지 수만 늘리는 것보다
클래스 다양성이 포함된 확장이
더 큰 차이를 만들 가능성을 확인

※ 완전한 인과 분리는 아니므로 추가 통제가 필요





모델을 바꾼 것이 아니라, 서로 다른 가설을 시험했다

one-stage / two-stage, multi-scale feature, class imbalance 대응을 병렬로 검증했다.

MODEL	BACKBONE	LOCAL mAP	NOTE	
SSD300	VGG16	0.4150	Baseline	1-STAGE
RetinaNet	ResNet50-FPN v2	0.35127	Public / 232	1-STAGE
Faster R-CNN	ResNet50-FPN v2	0.7986	Local / 10 epoch	2-STAGE
RTMDet-l	RTMDet	0.506	Local	1-STAGE
YOLO26S	YOLO26	0.986	Local*	1-STAGE

* YOLO26S의 0.986은 validation protocol 한계가 있어 일반화 성능으로 해석하지 않음.





0.986이라는 숫자를 ‘정답’으로 받아들이지 않았다

실제 코드와 데이터 구조를 다시 확인한 결과, validation 설계 자체가 일반화 성능을 과대평가할 수 있었다.

WHAT WE FOUND

Validation protocol mismatch

INTENDED

augmentation family split을 설계

ACTUAL

MultilabelStratifiedShuffleSplit · image-level 80:20

RISK

AI-Hub 근접중복 이미지가 train / valid에 함께 존재 가능

CONCLUSION

0.986을 최종 일반화 성능으로 채택하지 않음

RE-DESIGN

검증을 다시 설계한다

- 01 Near-duplicate 탐지
- 02 Group / family 정의
- 03 Group-aware split
- 04 Independent test
- 05 Robustness test

실제 코드 · GitHub `YOL0265_AIHub_Pill_Detection_wandb.ipynb`

노트북 설명: "augmentation family 단위로 분할" (의도)

```
splitter = MultilabelStratifiedShuffleSplit(...)
```

→ 실제로는 이미지 단위 80:20 분할

높은 점수보다 ‘독립적으로 재현되는 점수’가 중요하다.



모델이 틀린 게 아니라, 제출 파이프라인이 결과를 망치고 있었다

제출 파일 842장을 전수 검사해 confidence와 무관하게 항상 4개가 출력되는 구조를 역추적했다.



ROOT CAUSE

image당 **항상 4개** 예측을 출력

confidence가 낮은 예측도 강제로 제출

4순위 예측의 76%가 $\text{confidence} < 0.3$

threshold 0.3 / 0.5 실측 → threshold만으로 해결되지 않음

MODEL $\neq$ SYSTEM

버그 원인 · GitHub RetinaNet_ResNet50_FPN_v2.ipynb

주석: "사진당 알약 최대 4개" — 오해의 시작

```
order = scores.argsort(descending=True)[:4]
```

→ confidence 무시하고 무조건 4개만 제출



확장 데이터와 보정된 inference pipeline을 기준으로 최종 학습

최종 모델은 mAP 하나가 아니라 실사용 신뢰성까지 포함해 평가한다.

RETINANET

ResNet50-FPN v2

5-FOLD

100 EPOCH

8,068 images · 56 classes

현재 학습 진행 중

YOLO

YOLO 계열

150 EPOCH

TTA

8,068 images · 56 classes

보정 inference + TTA 기반 재검증

선정 기준

Detection · Localization · Generalization · Robustness · Safety · Latency



왜 최종 모델을 단순히 mAP로 선택하지 않았는가?

높은 Local mAP 하나만으로 실제 서비스 적합성을 판단하지 않고, 평가 신뢰성과 운영 조건까지 함께 봤습니다.

FINAL MODEL $\neq$ HIGHEST LOCAL mAP

01

DETECTION

mAP · Precision · Recall

얼마나 잘 찾는가

02

LOCALIZATION

IoU · BBox quality

얼마나 정확히 위치시키는가

03

GENERALIZATION

Group-aware validation

새로운 조건에서도 유지되는가

04

SAFETY

Unknown · Confidence Gate

모르는 입력을 구분하는가

05

PRODUCTION

Latency · Memory · Reproducibility

서비스에서 안정적인가



성능 숫자를 넘어, '어떻게 틀리는가'를 정의한다

실제 서비스에서는 평균 mAP보다 오류 유형별 대응 전략이 중요하다.

FALSE POSITIVE

없는 약을 있다고 탐지

FALSE NEGATIVE

있는 약을 놓침

CLASS CONFUSION

유사 약품을 다른 class로

BAD LOCALIZATION

bbox 위치·크기 부정확

UNKNOWN

학습 밖 대상을 기존 class로

IMAGE FAILURE

흐림·어두움·잘못된 사진

이 taxonomy가 있어야 '어떤 데이터를 추가할지 / 어떤 후처리를 바꿀지 / 어떤 모델을 재학습할지'가 결정된다.





모델의 confidence를 그대로 '정답'으로 보여주지 않는다

실사용 환경에서는 이미지 품질과 불확실성을 함께 판단하는 safety gate가 필요하다.



SAFETY GATE

확실하지 않으면
'확인 필요'로 전환

서비스 원칙

AI는 식별을 돕고 · 사용자는 최종 확인 · 불확실한 결과는 숨기지 않는다



Production AI Pipeline · Safety

모델의 raw prediction을 바로 사용자 결과로 보여주지 않고, 품질과 불확실성을 거친 뒤 결과로 연결하는 구조입니다.



모델 출력 상태를 분리

HIGH**결과 표시**

신뢰도 · 이미지 품질 조건 충족

MEDIUM**후보 + 확인**

추가 확인이 필요한 결과

LOW**재촬영 요청**

불확실성이 높은 결과

UNKNOWN**식별하지 않음**


No detection · 미등록 · 미확인 입력

AI가 항상 답을 내야 하는 것은 아닙니다.

확실하게 도울 수 있을 때는 결과를 보여주고, 확신할 수 없을 때는 '확인이 필요함'을 보여주는 구조가 필요합니다.

실제 서비스 데모 영상

촬영부터 AI 분석, confidence 표시까지 실제 기기에서 동작하는 화면입니다.



▶ 실제 촬영 → AI 분석 → 신뢰도 표시 (예시: 게보린정 300mg, 인식 신뢰도 49.4%)

Health Eat · 총 재생시간 1분 26초 · 편집 없이 실제 기기 화면 그대로입니다



다음 단계는 '더 큰 모델'이 아니라 '더 강한 일반화'다

현재 프로젝트에서 발견한 문제를 연구 과제로 연결해, 실제 촬영 환경에서 재현 가능한 시스템으로 발전시킨다.

01

VALIDATION

Group-aware split
Near-duplicate 제거
Independent test

02

ROBUSTNESS

Blur / low-light
Occlusion / background
OOD / unknown

03

LEARNING LOOP

Hard negative
Active learning
Model monitoring

PROJECT PRINCIPLE

높은 mAP를 만드는 것에서 끝나지 않고, '언제 믿을 수 있는가'를 검증하는 AI를 만든다.



모델 성능을 넘어, 전체 파이프라인의 신뢰도를 높입니다.

이번 프로젝트에서 확인한 문제를 데이터 품질과 검증 신뢰성의 개선 과제로 연결했습니다.

01

DATA QUALITY

데이터가 흔들리면
모델의 성능도 흔들립니다.

학습 이전에 데이터의 구조·좌표·라벨·중복을 자동 검증하는 체계가 필요합니다.

발견한 문제

- area:null / BBox 오류
- 중복 Annotation
- 클래스 충돌
- dL_idx / 매핑코드 불일치
- AI-Hub 유사 이미지

개선 방향

- Annotation Schema · BBox 자동 검증
- 중복·유사 이미지 탐지
- Class Mapping Version 관리
- Canonical Label 고정
- Dataset Integrity Check

02


VALIDATION RELIABILITY

높은 점수보다
믿을 수 있는 점수.

Local mAP가 실제 일반화 성능을 대표하는지 검증하기 위해 split 전략 자체를 개선합니다.

기존

개선



핵심 | 깨끗한 데이터 → 믿을 수 있는 검증 → 실제 서비스에서 재현되는 성능

다음 단계는 ‘더 높은 점수’가 아니라 ‘더 견고한 AI’입니다.

실제 촬영 환경과 불확실성까지 고려해, 탐지에서 안전한 확인까지 확장합니다.

01

ROBUSTNESS

촬영 환경 일반화

실제 사용자 촬영 이미지에서 성능 변동을 줄입니다.

각도

조명

배경

초점

모션 블러

저조도

→ Real-world Augmentation

Domain Shift 대응을 위한
실환경 중심 데이터 확장

02

OOD / UNKNOWN

모르는 상황을 구분

모델이 확신할 수 없는 경우를
‘확인 필요’로 전환합니다.

KNOWN정상 결과

LOW QUALITY재촬영

UNKNOWN확인 필요

NO DETECTION식별 불가

Confidence / OOD Gate

03

IDENTIFICATION

탐지에서 확인까지

Detection 결과를 후보 매칭과
사용자 확인으로 연결합니다.

IMAGE

QUALITY CHECK

DETECTION

CANDIDATE MATCHING

MEDICINE DB

USER CONFIRMATION

완료

탐지 → 확인까지 하나의 AI 흐름

마무리

우리가 만든 것은 단순한 모델이 아니었습니다.

“AI가 모든 약을 맞히는 서비스를 만들고자 한 것이 아닙니다.”

AI가 확실하게 도울 수 있는 순간과,
사람이 반드시 확인해야 하는 순간을 구분하는 서비스를 만들고자 했습니다.

01

MODEL

높은 mAP보다
검증 가능한 성능

02

DATA

많은 데이터보다
믿을 수 있는 데이터

03

SERVICE

정확한 답보다
안전한 답변 구조

HEALTH EAT · BETTER HEALTH, TOGETHER

감사합니다.



Health Eat

더 건강한 일상을 위한 AI

“문제를 해결하는 것보다
문제가 어디에 있는지 찾는 과정이
더 어려웠습니다.”

김혜린

PM / Data Pipeline

“데이터를 많이 만드는 것과
좋은 데이터를 만드는 것은
달랐습니다.”

강인호

Data / Model

“높은 점수가
반드시 좋은 모델을
의미하지는 않았습니다.”

유영관

Model / Experiment

Our Team

팀 회고

14기 2팀

2026.09.23



Health Eat

Data Science

Machine Learning

Computer Vision